南京农业大学

智慧农业学院（人工智能学院）　课程实践报告

智能科研助理系统

模块五：系统评测与项目交付

55 题 Agent 基线　/　495 条检索实验　/　证据驱动分析

课程	生产实习（1 学分）
学年学期	2026–2027 学年第 1 学期
负责成员	B：_____（姓名待填）
学号 / 班级	_____
指导教师	_____
报告日期	2026 年 10 月 14 日

报告范围：整理成员 B 已完成的语料与评测集准备、实验组织、AI 辅助评分、检索参数分析与错误归因。质量评分尚待独立人工复核；生成/Agent 修复后的质量复测及全项目真实界面截图列为待验收项。姓名、学号等空白项由本人填写。

摘 要

本报告依据课程实践方案与项目交付模板，记录成员 B 在模块五的阶段性工作。在去重后的 15 篇、296 个物理页的本地文献上，建立包含事实、对比、总结和推理四类的 55 题评测集，并完成 55 题 Agent 基线及 3 档递归字符分块长度、3 种检索方式组成的 495 条独立检索实验。评测保留失败样本、逐题时延、实际模型调用 Token、工具轨迹和运行来源；使用固定参考答案及原文证据开展 AI 辅助量表评分。

Agent 基线有 53 题执行成功，自动工具集合匹配为 46/55；这两项均不代表答案正确率。正确性、完整性和引用准确性均分分别为 0.9818、0.8182、0.9636（满分 2）。在本次检索实验中，512 字符分块配合混合检索与重排获得 Hit@5=83.64%、MRR@5=0.6245、Recall@5=72.73%，平均查询耗时 1.7860 秒，适合作为后续固定基线。错误分析显示，工具选择、论文范围绑定以及证据到回答的忠实映射仍需改进。本报告提供可追溯的数据、矢量图表和复现说明，不将参数筛选或运行恢复误写为已完成的答案质量优化闭环。

关键词：检索增强生成；Agent；页级证据评测；参数对比；AI 辅助评分；Bad Case

目 录

摘要 **I**

一 项目概述 **1**

1.1 项目背景 1

1.2 目标与报告边界 1

1.3 实际技术栈 1

二 团队分工说明 **2**

三 各模块交付物清单 **3**

3.1 模块一：文档处理与检索 3

3.2 模块二：RAG 生成 3

3.3 模块三：Agent 3

3.4 模块四：集成与界面 4

3.5 模块五：系统评测与交付 4

四 技术实现记录 **4**

4.1 模块一：文档与索引接口 4

4.2 模块二：生成与计量接口 5

4.3 模块三：Agent 执行与轨迹 5

4.4 模块四：集成与截图材料 5

4.5 模块五：评测集与实验设计 7

4.5.1 数据集构建与覆盖 7

4.5.2 检索指标定义 8

4.5.3 固定条件与测量边界 8

4.6 检索参数实验结果 9
4.7 Agent 效率与工具表现 11
4.8 AI 辅助量表评分 13
4.8.1 评分规则与溯源 13
4.9 Bad Case 分析与优化交接 14

五 技术设计文档 16

5.1 评测数据契约与输出结构 16
5.2 可追溯性与续跑设计 17
5.3 运行异常与工程改进记录 17
5.4 图表与报告生成设计 17

六 总结与展望 18

6.1 已完成成果与主要认识 18
6.2 课程验收前的后续工作 18

七 附录 19

7.1 环境与关键配置 19
7.2 独立报告文件夹与编译 19
7.3 本地实验复现命令 20
7.4 原始记录与数据来源 21
7.5 依据文档 22
7.6 文献清单 22
7.7 55 题评分明细 23

一、项目概述

1.1 项目背景

科研文献数量持续增加，人工查找实验配置、比较方法和核验结论耗时较长。本项目构建基于本地论文知识库的智能科研助理，通过检索增强生成与工具调用，支持证据查询、论文比较及归纳推理。成员 B 负责以固定问题集检验检索、回答、引用与运行效率，为系统改进提供可复查依据。

1.2 目标与报告边界

模块五的核心目标是形成“数据准备—执行测量—答案审阅—错误分析—改进复测”的可追溯过程。本阶段完成前三项及错误分析，并形成检索参数选择依据与优化交接清单；修改后答案质量复测尚未完成。报告按交付模板的七章结构组织，其他模块只说明评测依赖与可观察状态，完整验收由对应负责人补齐。

评测资料与报告整理使用了 AI 辅助，55 题质量分数来自 AI 对固定参考答案、实际回答、可见工具轨迹及原文页的审阅。它们不是独立人工实验，也不是教师评分。课程要求的人工评估仍需本人或独立评审者复核并签署记录。

1.3 实际技术栈

被测系统采用 Python、pdfplumber、Chroma、BM25、RRF 融合、BGE 嵌入与重排、Ollama 本地语言模型，以及 Streamlit 前端。评测层独立记录 JSONL、CSV 和 JSON，再由 Python/Matplotlib 生成统计图，以 LaTeX 组织报告。实验模型与主要配置见附录表13，不据此推断未实测的并发能力或部署能力。

二、团队分工说明

表 1 团队约定分工与本报告归属

成员	姓名	主要职责	对应模块	约定比例
A	待本人填写	前端交互、页面呈现和界面材料	模块四前端	15%
B	待本人填写	评测集、实验运行、评分审阅、错误分析、交付文档	模块五	15%
C	待本人填写	文档处理、分块、检索与 RAG 生成后端	模块一、二	35%
D	待本人填写	Agent 工具、路由与系统集成	模块三、四集成	35%

注：比例来自团队分工方案，合计 100%，不等同于自动统计的实际代码贡献。本报告不代替其他成员的工作验收。

成员 B 的实际工作包括：在 AI 辅助下整理与核验 15 篇语料和 55 题参考证据；在本地环境组织模型预检、正式运行与中断恢复；完成 9 组检索参数的结果对照；开展有审计记录的 AI 辅助评分；整理四类 Bad Case 及修复建议；冻结数据并制作本报告图表。检索与 Agent 业务代码分别作为 C、D 提供的被测依赖，不能因 B 运行了评测便将其实现归为 B 的独立开发成果。

三、各模块交付物清单

3.1 模块一：文档处理与检索

表 2 模块一的评测依赖与验收边界

项目	观察状态	依据或待补事项
PDF 加载与索引	已调用验证	15 篇共 296 页；512 档形成 2082 块。
Word / TXT 加载	待实现或核验	当前加载器为 PDF，不宣称已支持所有格式。
分块与质量对比	部分完成	已测 recursive 的 256/512/1024 长度；三类分块策略质量比较待补。
向量、混合、重排	已完成本轮	三档长度各 55 题 × 3 种检索，共 495 条。
嵌入与向量库对比	待完成	本轮固定 BGE 与 Chroma，未测 m3e/FAISS 对照。
增量索引	待核验/改进	当前建库全量重建；复用已有索引不是增量更新。

3.2 模块二：RAG 生成

表 3 模块二的评测依赖与验收边界

项目	观察状态	依据或待补事项
上下文生成与引用	可调用，质量待改进	Agent 调用了 RAG 工具；有引用错配和信息遗漏。
解码参数实验	待完成	未完成 temperature/top-p/top-k 的独立质量对照。
真实流式与语义缓存	未验证	前端逐字展示不能作为模型 Token 流式的证据。
日志与异常恢复	部分验证	有真实调用、耗时及失败记录；完整降级验收由 C/D 补齐。

3.3 模块三：Agent

表 4 模块三的评测依赖与验收边界

项目	观察状态	依据或待补事项
工具调用与 ReAct	已评测基线	55 题中 27 题走 ReAct，28 题直接工具路由。
工具数量与参数	部分完成	当前 7 类工具；课程 8 类目标及参数契约需负责人核验。
错误恢复与论文绑定	待修复复测	F07/F12 抛出类型异常；存在论文范围误匹配。
记忆与健康检查	本轮未验收	本轮关闭跨题记忆；不能推断多轮记忆质量。

3.4 模块四：集成与界面

表 5 模块四的评测依赖与验收边界

项目	观察状态	依据或待补事项
前端代码与服务接口	已交付代码	本报告不据文件存在推断全部页面已端到端验收。
历史记录与核心交互	待界面验收	需 A/D 在真实运行界面核验。
3–5 张真实界面截图	待补齐	模板 4.4.2 的全项目要求；本报告数据图不替代界面截图。

3.5 模块五：系统评测与交付

表 6 成员 B 的交付与尚待闭环事项

交付项	状态	可复查证据
10–20 篇、50+ QA	已完成	15 篇、55 题、四类问题与原文证据。
检索质量与参数图表	已完成本轮	9 组配置、495 条结果与逐题指标。
Agent 与效率基线	已完成本轮	55 题，保留 2 个执行失败及全部计量字段。
质量评分	AI 辅助完成	55 题逐项评分、证据及审计；独立人工复核待补。
四类 Bad Case	已完成分析	检索/生成/引用/Agent 多标签与代表案例。
质量优化前后复测	待完成	已形成 C/D 交接建议，尚无修复后 55 题结果。
技术与使用说明	本报告已整理	设计、复现命令、结果说明与源文件。

四、技术实现记录

4.1 模块一：文档与索引接口

本轮从项目论文目录筛选文献，剔除同文重复版本与主题外指南，冻结 PDF 文件名和 SHA-256。物理页码从 1 开始，避免印刷页码与 PDF 顺序页混淆。索引流程采用文本提取、递归字符分块、BGE 嵌入、Chroma 存储，再组装 BM25 和融合检索。512 档复用了经过文本、页码、块 ID 与嵌入配置验证的 2082 个已有块；其建库时间不与新建索引直接比较。

4.2 模块二：生成与计量接口

回答链路使用 Ollama 的 `qwen2.5:7b`。调用级 Token 计数聚合实际返回的 prompt/completion 字段；单题若存在未完整计量的调用，不将缺失值伪装为零。本轮 55 题 Token 覆盖率为 100%。预热、索引组装与模型加载耗时不并入逐题问答时延。各工具保留原有解码配置，本报告不将预检温度或某一路生成温度称为全链路统一参数。

4.3 模块三：Agent 执行与轨迹

系统根据规则直接调用工具，或进入 ReAct 循环。评测记录实际工具集合、参数、返回状态、执行模式和步数。`success=True` 仅表示后端声明执行成功；S10 等题可能只返回诊断性文本，因此必须再检查回答内容。自动工具集合匹配与 AI 对参数及任务意图的路由判断分开统计，避免把两个定义不同的指标混为一个准确率。

4.4 模块四：集成与截图材料

本阶段通过脚本调用实际后端完成基线。图1为代码依赖及评测数据流示意，不是界面截图。模板要求的真实截图应由 A/D 在系统运行时补充，建议覆盖文献加载、带引用问答、论文比较、工具轨迹及历史记录，并标注核心区域。本报告没有将模拟网页或数据统计图充作该项证据。

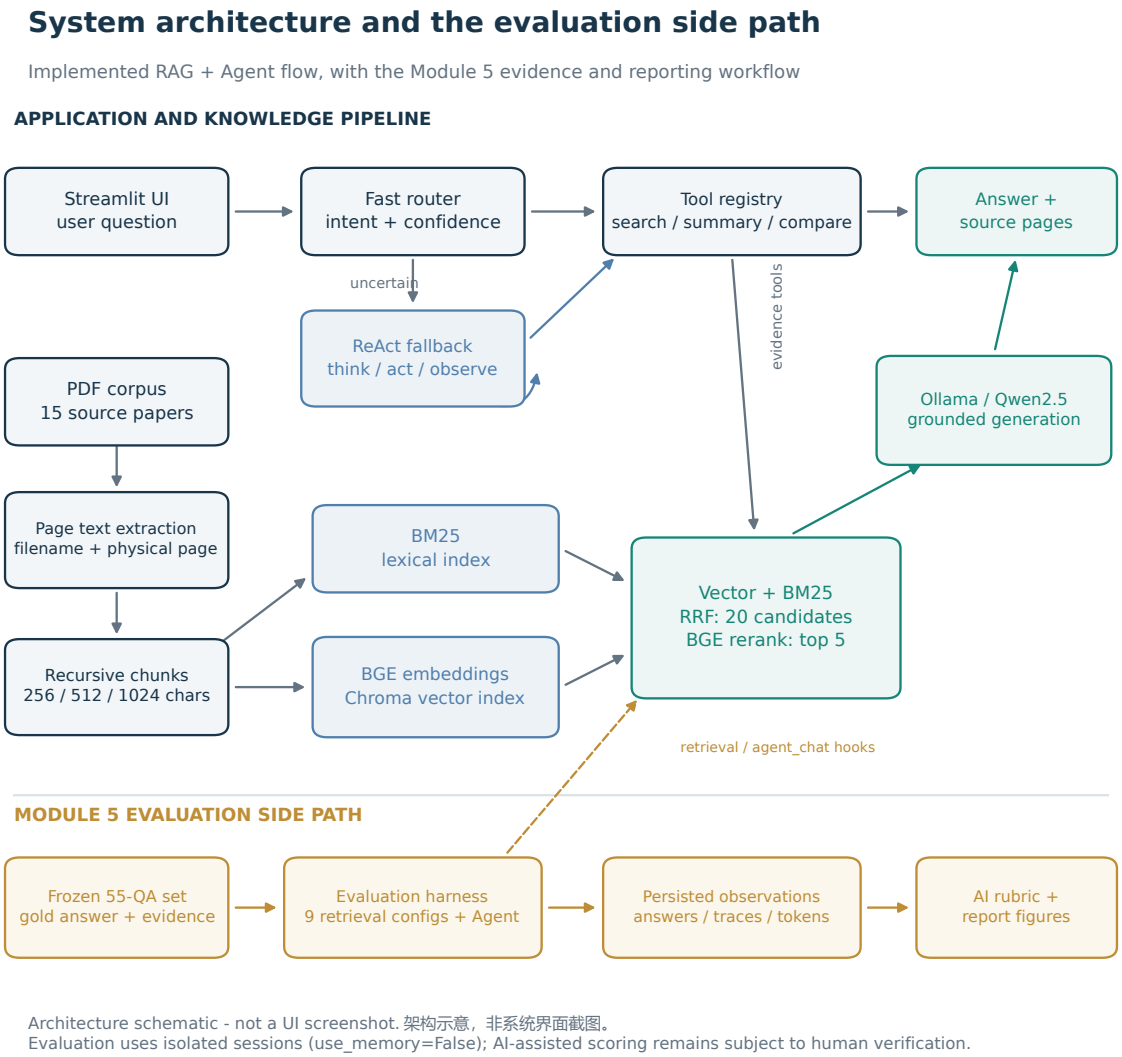


图 1 被测系统与成员 B 评测流水线。架构示意图；实线表示调用或数据传递，评测层负责冻结输入、计量与审阅。

4.5 模块五：评测集与实验设计

4.5.1 数据集构建与覆盖

语料为视觉表征、语义分割及视觉应用研究，另纳入作为 Transformer 理论基础的 *Attention Is All You Need*，不将 15 篇都称为视觉应用论文。构造事实 20 题、对比 15 题、总结 10 题、推理 10 题。每题保存 ID、问题、参考答案、证据 PDF/物理页/摘录、可接受工具集合；共核验 142 条证据记录。论文题名与页数见附录表15。

为保持任务独立性，本轮关闭跨题会话记忆。Agent 各题只执行一次正式基线；三档分块各完成向量、混合、混合加重排三种检索。所有检索配置使用相同 55 题、相同语料与相同后端指纹。图2中的论文覆盖按题目引用的金标证据去重统计；一题可覆盖多篇论文，因此论文列的计数之和可以大于 55。

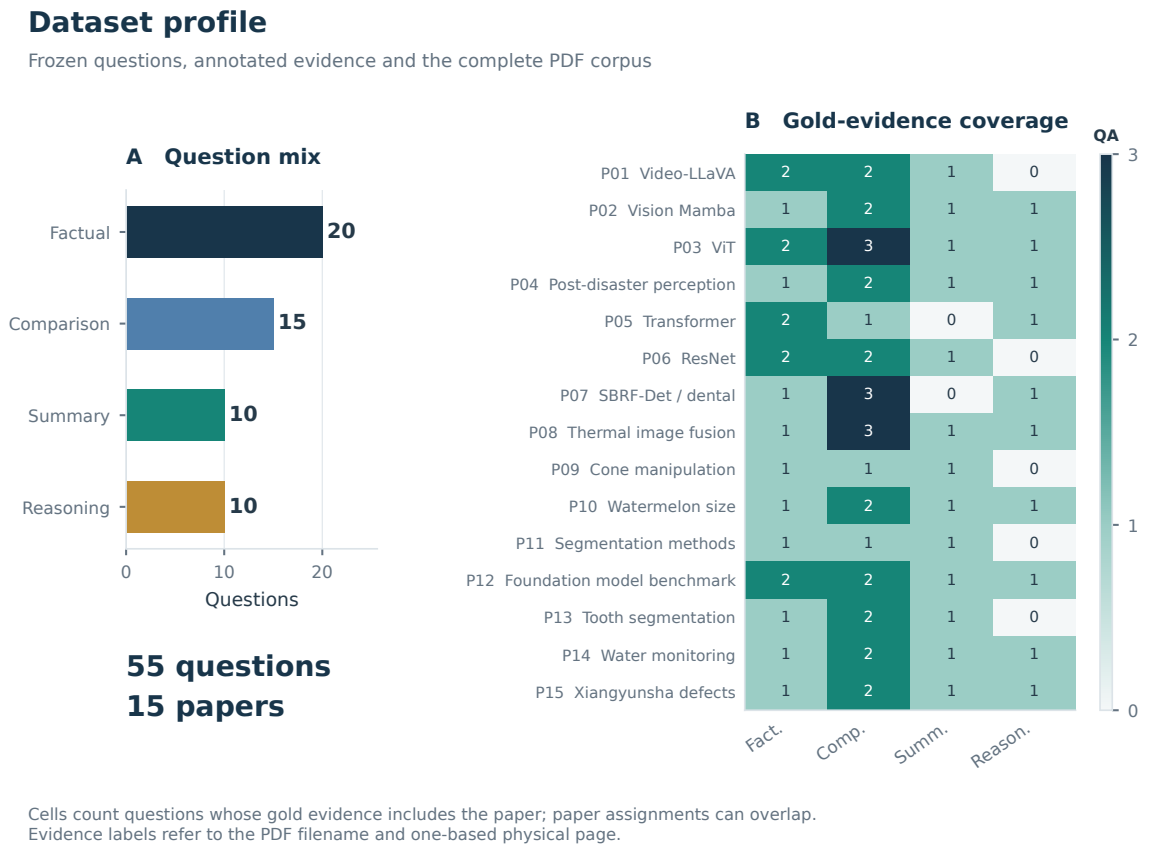


图 2 评测集结构与论文证据覆盖。四类问题共 55 题；P01–P15 的题名对应附录清单。覆盖数量表示关联题数，不是独立问题总数。

4.5.2 检索指标定义

设第 i 题的去重金标证据页集合为 G_i，前 5 个检索块对应页的集合为 $P_i^{(5)}$，r_i 为前 5 名中首次命中金标页的块排名。证据单位为“精确 PDF 文件名 + 物理页”。

$$\text{Hit@5} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{1}[G_i \cap P_i^{(5)} \neq \varnothing], \tag{1}$$

$$\text{MRR@5} = \frac{1}{N}\sum_{i=1}^{N}\begin{cases}1/r_i, & r_i \leq 5,\\ 0, & \text{前五名无命中},\end{cases} \tag{2}$$

$$\text{Recall@5} = \frac{1}{N}\sum_{i=1}^{N}\frac{|G_i \cap P_i^{(5)}|}{|G_i|}. \tag{3}$$

重复同页块不增加 Recall 的已覆盖证据页数，MRR 仍按块的原始排名计算。页级命中不证明整页已进入模型上下文，也不证明答案结论正确。Agent 汇总引用可能来自多次工具调用，没有统一 Top-5 排名，因而其检索三指标为 N/A；下文检索成绩全部来自独立 retrieval 模式。

4.5.3 固定条件与测量边界

本轮均使用 recursive 字符分块，长度参数为 256/512/1024，overlap 参数为 50，候选召回 20、最终 Top-5。当前实现不保证每一对输出块都有恰好 50 字符重叠，因此不把配置值解释为实际重叠量保证。嵌入及重排在 CPU 执行，语言模型由 Ollama 管理设备；本报告没有连续 GPU 利用率测量。

55 题 Agent 基线属于中断后续跑：先前已落盘的 23 题保留原始回答、计时与 Token，后续运行执行余下 32 题，各题记录来源。早期异常运行、预检和 3 题冒烟结果不计入正式 55 题。不能用最后一段进程起止时间代表整轮耗时。三档检索都是单次顺序运行，没有重复采样、误差棒或显著性检验。

4.6 检索参数实验结果

表 7 九组检索配置的总体表现（每组 $n = 55$）

块长（字符）	文本块（个）	检索方法	命中（题/55）	Hit@5（%）	MRR@5	Recall@5（%）	平均查询（s/题）
256	4 335	向量	38/55	69.09	0.550	57.58	0.163
		混合（RRF）	40/55	72.73	0.575	59.24	0.192
		混合＋重排	42/55	76.36	0.591	64.24	1.312
512	2 082	向量	39/55	70.91	0.576	59.85	**0.142**
		混合（RRF）	39/55	70.91	0.587	58.03	0.148
		混合＋重排	**46/55**	**83.64**	**0.625**	**72.73**	1.786
1024	1 079	向量	40/55	72.73	0.550	57.12	0.159
		混合（RRF）	42/55	76.36	0.610	61.97	0.164
		混合＋重排	**46/55**	**83.64**	0.592	71.36	3.258

每配置 $n = 55$；共 495 次检索，均为递归字符分块。相关性以文件名与 PDF 物理页共同匹配。粗体表示九配置中的最优值（延迟取最小），并列最优均标粗。

注：V= 向量，H= 混合，H+R= 混合加重排。查询时延不含建库；512 档复用已有索引。

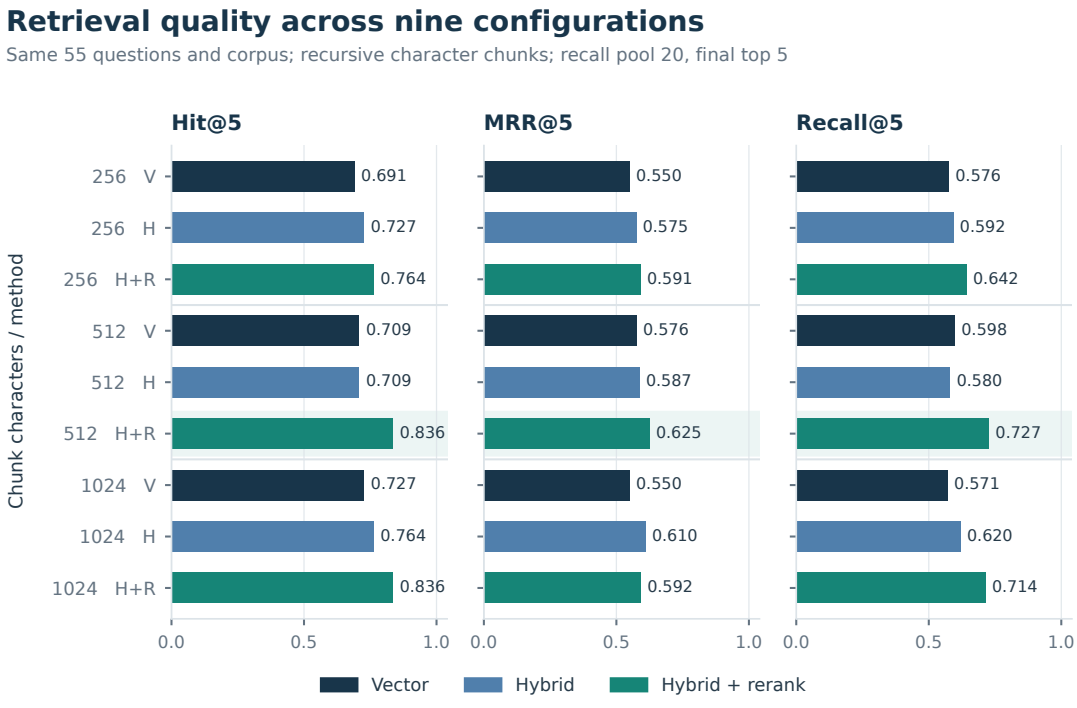


图 3 三档分块长度与三种检索方式的质量比较。相同题集与金标页定义下，分别展示 Hit@5、MRR@5、Recall@5；未绘制未经重复实验估计的误差棒。

512+H+R 命中 46/55 题，相对同长度向量检索的 39/55 多命中 7 题，Hit@5

增加 12.73 个百分点；Recall@5 从 59.85% 增至 72.73%。重排提高了本轮证据覆盖，但查询时延从 0.1416 秒增至 1.7860 秒。混合本身并不在所有配置和指标上优于向量：512 档两者命中数相同，而混合 Recall 略低，应保留这一结果。

1024+H+R 同样命中 46 题，但 MRR 为 0.5921，Recall 为 71.36%，平均 3.2577 秒。512 档在命中数相同的情况下排名与覆盖更好，耗时约少 45.2%。256+H+R 更快，但少命中 4 题。故 512+H+R 是本数据集上合理的后续固定基线；这一判断不是对所有任务的通用最优证明。

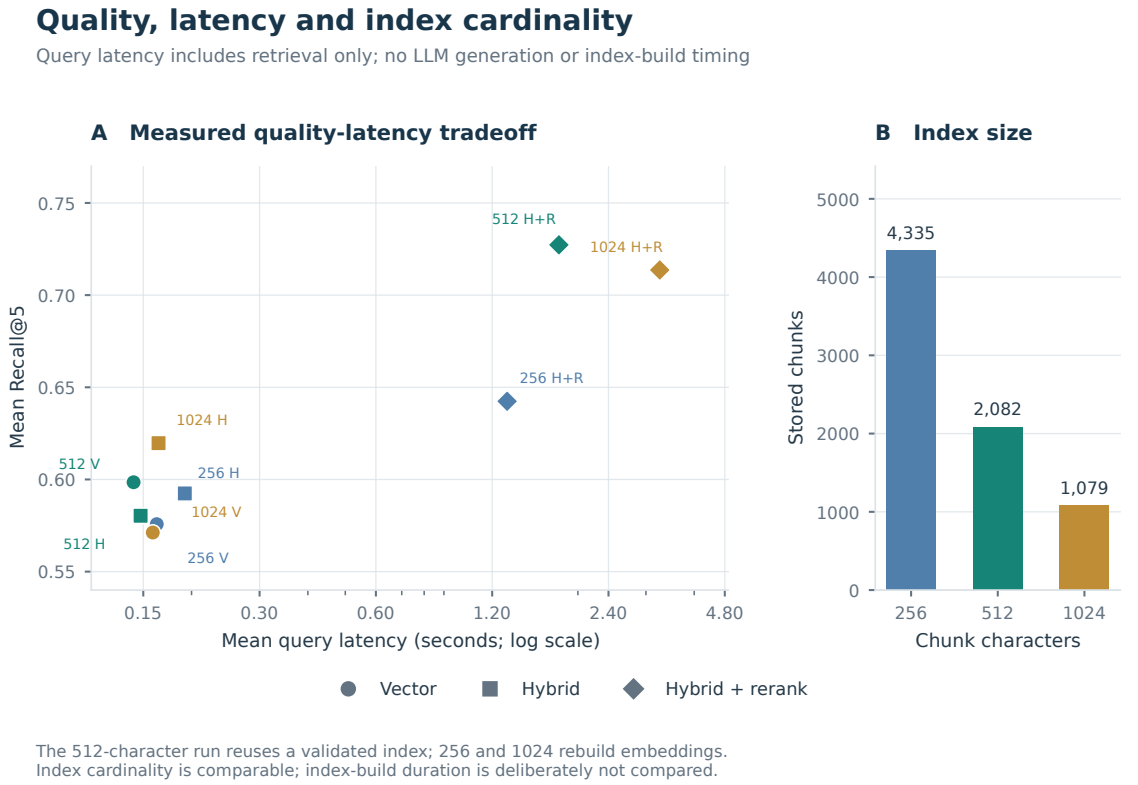


图 4 检索质量、查询时延与索引规模。时延仅比较查询过程；块数刻画索引规模，不用复用索引的零建库时间制造速度优势。

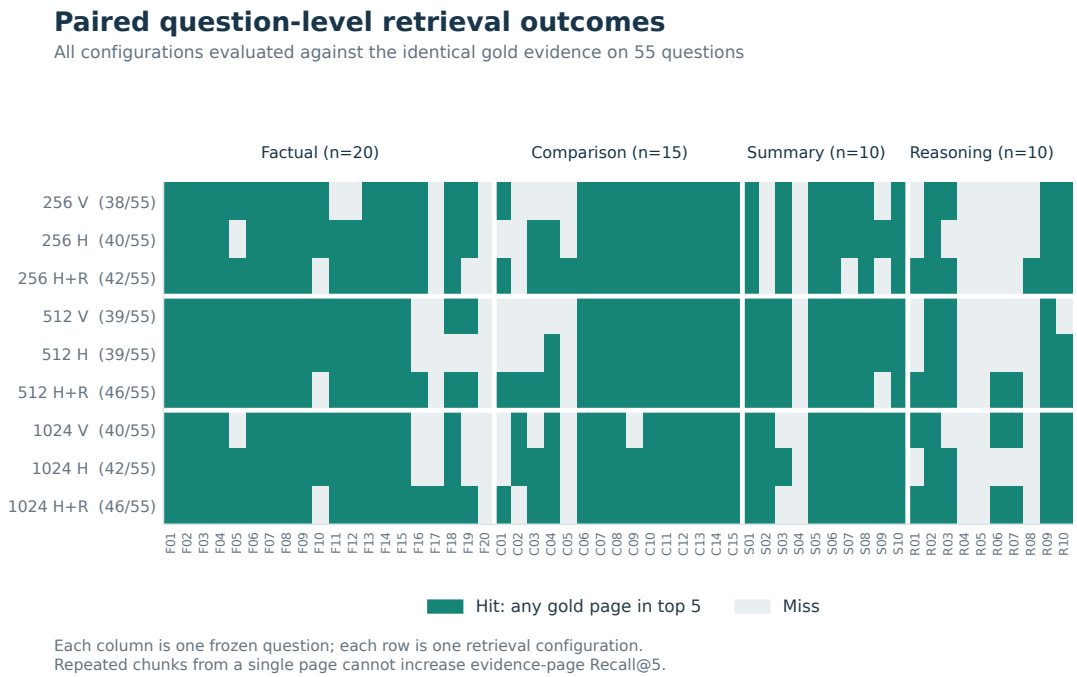


图 5 相同 55 题在九组配置中的逐题命中情况。每格为该题是否至少命中一个金标证据页；分组展示四类任务，便于定位总体均值掩盖的差异。

4.7 Agent 效率与工具表现

表 8 55 题 Agent 基线：执行、工具和效率指标

指标	结果	分母与判定口径
执行成功率	53/55（96.36%）	后端执行标志；包含失败题。
自动工具集合匹配率	46/55（83.64%）	与预标允许工具集合精确匹配；不评估参数语义。
AI 辅助语义路由合理率	45/55（81.82%）	AI 同时检查选用工具、调用参数与完整任务意图。
平均端到端延迟	64.096 s	$n = 55$；包含失败题与保留的原始测量。
P95 端到端延迟	168.346 s	$n = 55$；按冻结汇总的第 95 百分位口径。
平均执行步骤	1.20 步/题	$n = 55$；含直接工具执行与 ReAct。
ReAct 平均执行步骤	1.41 步/题	仅 $n = 27$ 个 ReAct 请求。
完整计量 Token 总量	241 703 token	$n = 55$；每题所有 LLM 调用的输入与输出之和。
平均 Token 消耗	4 394.6 token/题	分母为 $n = 55$ 个计量完整的题目。
Token 计量覆盖率	55/55（100.00%）	缺失计数不按零处理。

自动工具匹配与 AI 语义路由是不同指标。评分未作独立人工复核；执行成功不等于答案正确。

注：失败题保留在总体分母与计量中；ReAct 步数只对其 27 题求均值。模式间时延差异受题目类型影响，不能当作同题随机对照。

53/55 的执行成功率为 96.36%，但执行完成并不能推导内容正确。自动工具集合匹配为 46/55（83.64%），AI 结合意图及参数审阅后的路由有效为 45/55（81.82%）；例如 S09 可接受语义上的论文比较，但预标注集合不含该工具，两个口径可能不同。保持原始标注不变，同时保留差异解释。

逐题平均墙钟时延为 64.0958 秒，P95 为 168.3460 秒，平均实际调用 Token 为 4394.6。直接工具路由 28 题平均 102.3914 秒，ReAct 27 题平均 24.3818 秒；对比类任务全部走直接工具路径，题目组成不同，不能据此声称 ReAct 本身必然更快。总体平均步数 1.2，ReAct 子集平均 1.4074，后者才适合描述实际循环推理步数。

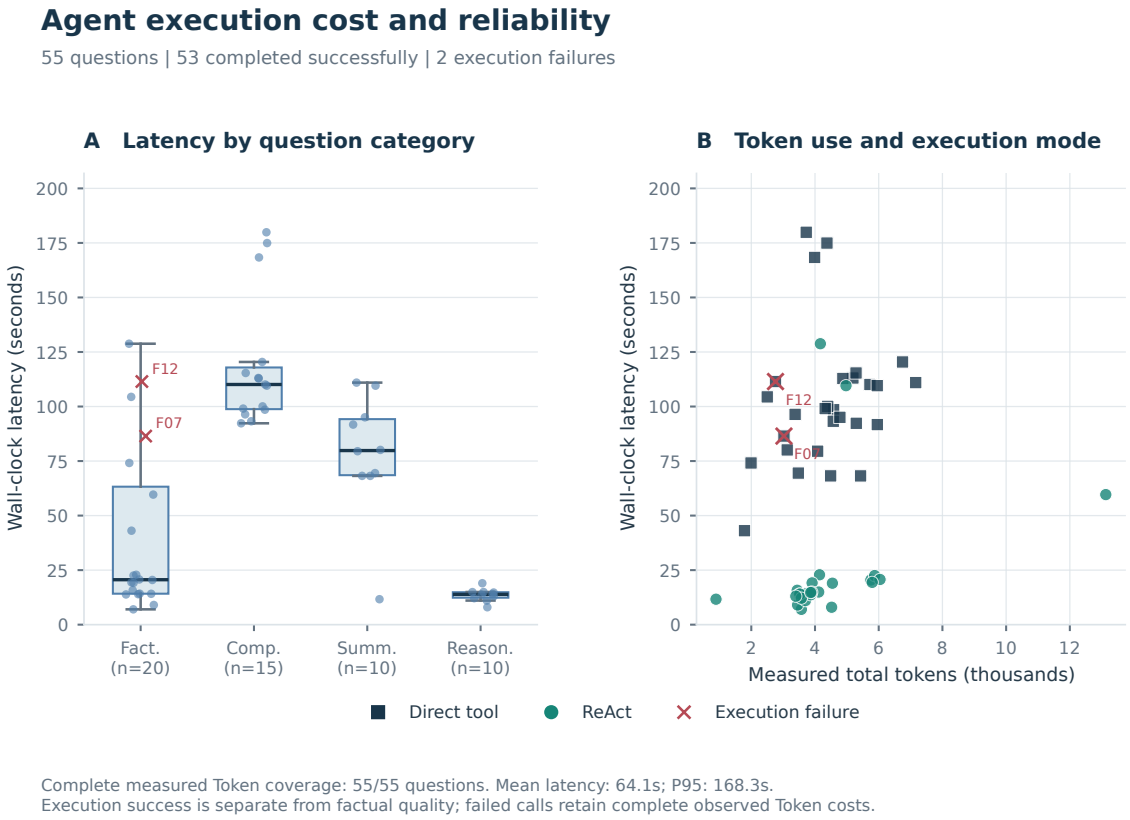


图 6 Agent 的逐题效率分布与实际 Token 消耗。保留失败样本，按类别和执行模式展示；每个点表示一个问题，模式对比为观察性描述。

4.8 AI 辅助量表评分

4.8.1 评分规则与溯源

正确性、完整性、引用准确性各按 0/1/2 评分，分别表示核心无效、部分满足、完整满足相应标准。正确性关注关键事实与内部矛盾；完整性关注所问要点覆盖；引用准确性关注实际返回的文件/页能否支持表述。路由采用 0/1，检查工具意图及关键参数。评分参考固定参考答案与真实原文，不只看最终一句是否包含目标数字；执行失败按无有效回答处理。

评分文件记录逐题原因、核对页及不确定性。C01 的“无归纳偏置”绝对化表述被复核为部分正确；C14 虽错误绑定 Vision Mamba，ResNet 部分仍有真实支持，因此三个量表均为 1，而非全部归零。F11 的“最多重试三次/总共尝试三次”在原论文摘要与正文存在表述差异，保留不确定性，不额外据此扣分。原始回答、参考答案和运行元数据没有为获得更好成绩而改写。

表 9 四类问题的 AI 辅助质量评分（各质量维度满分 2）

问题类别	n	正确性（0–2）	完整性（0–2）	引用准确性（0–2）	AI 语义路由合理率（%）
事实	20	0.700	0.750	0.650	60.00
对比	15	1.133	0.733	1.133	100.00
归纳	10	1.000	0.700	1.000	80.00
推理	10	1.300	1.200	1.300	100.00
总体	**55**	**0.982**	**0.818**	**0.964**	**81.82**

三项答案评分取 0、1、2 分；表中为均值。各维度均覆盖对应类别全部题目，失败题保留。语义路由逐题判 0/1，结果为 AI 辅助评分。

注：全部 55 题均有评分；“路由”是 AI 语义判断的 0/1 比例。结果尚待独立人工复核，量表均分不是二元答案正确率。

总体正确性、完整性和引用准确性分别为 0.9818/2、0.8182/2、0.9636/2。完整性是三个量表中的最低项。事实类部分题被错误送入元数据工具，导致实验数值或配置缺失；对比类虽工具集合匹配较高，仍会因论文绑定错误或只回答一部分要点而失分。推理类表现相对较好，但样本仅 10 题，不能据此推广到所有推理任务。

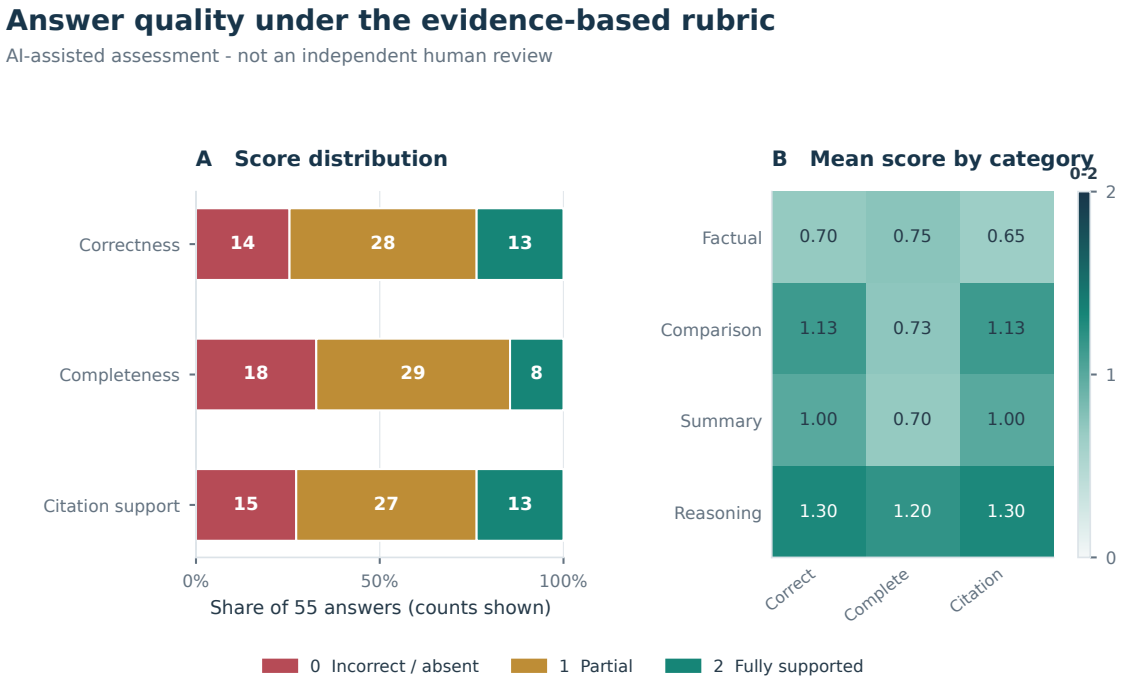


图 7 AI 辅助评分分布与分任务均值。正确性、完整性、引用准确性均为 0–2 量表；不将其标为独立人工实验或自动正确率。

4.9 Bad Case 分析与优化交接

四类错误采用可重叠标签：检索 10 题、生成 39 题、引用 42 题、Agent 11 题，均来自 AI 辅助诊断。相加为 102 次标签，而非 102 个独立失败题。某题可同时出现范围错配、错误生成与引用不支持；图8因此采用计数和共现矩阵，不将四类绘成互斥饼图。

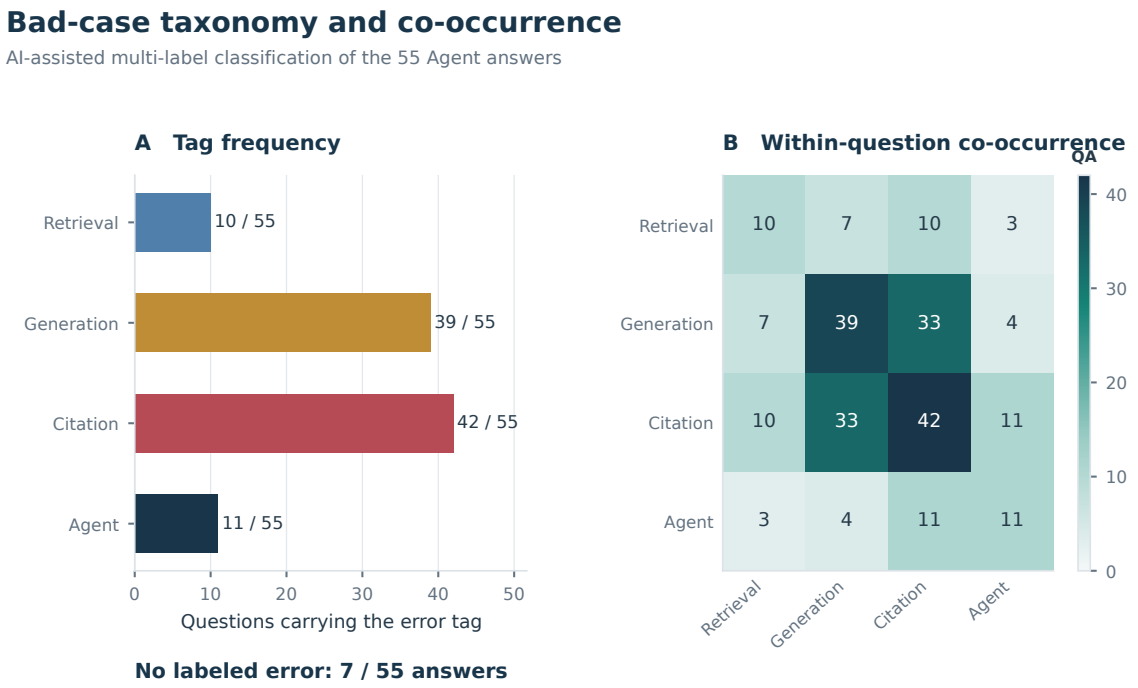


图 8 四类 Bad Case 的多标签计数与共现。对角线为各类涉及题数，非对角线为两类共同涉及的题数；标签表达审阅判断，不单独证明模型内部因果。

表 10 代表性问题、可见证据与下一步处理

题号	主要问题	已观察现象	核查证据与待验证改进
F02	生成 / 传参偏移	将集成模型测试集 3.57% 误写为单模型验证集结果。	P06，第 2、7 页区分两种设置；建议保留原题限定，并逐项绑定模型、数据划分与指标。
F07	Agent 执行失败	事实问题误走元数据工具，字符串拼接 TypeError 导致无答案、无引用。	P12，第 1 页包含所问设置；建议修正意图判定、规范字段类型，并保留真实失败状态。
F16	检索证据缺失	未返回 ViT 数据集规模所在页，最终拒答三组类别数 / 图像数。	P03，第 4 页有完整数据；建议约束目标来源与章节，再检验召回和答案完整性。
C14	来源匹配 / 生成	Vim 匹配成另一篇论文；又将 ResNet 的 ImageNet 指标误归 CIFAR-10。	P02，第 2、5 页及 ResNet 第 7 页可核对；建议使用确定的题名—文件映射，并按数据集组织证据。
S10	任务分解 / 状态	三篇论文被交给双篇比较工具；返回错误信息，却以 success=True 结束。	三篇原文第 1 页均有相应内容；建议逐篇抽取后汇总，并将工具失败状态向上传递。
R08	推理归因错误	以色彩基线缺少端到端评估，解释复合规则 0/102 不能算独立验证误报率。	P14，第 8、11 页说明同集设计偏差及冻结后独立验证；建议区分评估对象、设计集与验证集。

案例由冻结的 AI 辅助评分与实际结果归纳；P 编号对应文献表，页码均为 PDF 物理页。改进为待实施、待复测建议，不代表已取得优化后结果。

注：案例均保留原回答及轨迹；原文页出现在 sources 中，只证明页级可见支持，不能还原未记录的全部内部上下文。

优先改进顺序为：第一，修复 `paper_metadata` 的结构化作者字段拼接异常，并将实验结果、训练配置等事实查询路由到证据检索；第二，为论文比

较与总结加入显式文献 ID 绑定，防止 Vision Mamba 指向语义分割基准论文；第三，检查回答要点覆盖与数值语境，避免把测试集集成结果改写为验证集单模型结果；第四，引用生成前核验结论与证据的一致性，并对纯诊断性文本设置任务完成检查。

修复应由 C/D 在各自代码中实施，B 使用同一 55 题和固定基线重新运行，保留新版哈希、逐题评分与错误迁移表。当前没有该轮结果，因此本报告没有虚构优化后数值，也没有把本轮长度参数筛选替代课程要求的答案质量优化前后对照。

五、技术设计文档

5.1 评测数据契约与输出结构

QA 输入以 JSONL 一行一题，核心字段为 `id/category/question/reference_answer/gold_evidence/accepted_tool_sets`。gold 包含 `source/page/evidence`，文件名与物理页组成严格匹配单位。运行结果补充 `success/answer/sources/tools_used/steps/execution_mode/wall_latency_s/token_usage`，原始轨迹保存在嵌套对象中。

每次正式运行创建独立目录，包含参数及指纹元数据、QA 快照、逐题结果、审阅表和汇总。自动指标从逐题结果重新计算；量表评分与其来源另存审计，防止未经评分的旧汇总与新版混用。报告包的 `data/report_data.json` 冻结 55 题 Agent、495 条检索、评分与语料记录，图表脚本只消费该快照，不调用模型。

5.2 可追溯性与续跑设计

可比性由 QA/语料 SHA-256、后端文件指纹、模型名、包版本与配置共同约束。续跑采用新输出目录，按题 ID 去重复制已落盘结果，仅执行缺失题，并保留 `origin_run_id`。索引复用需验证语料、分块与嵌入配置以及已存块的文本/页码/ID，而不是仅检查“目录存在”。对历史片段未保存的模型快照或计量脚本指纹，明确保留不可追溯边界，不事后伪造。

5.3 运行异常与工程改进记录

表 11 本地运行异常及已实施的评测工程处理

现象	可见证据与处理	验证边界
模型缺失 / 显存分配失败	预检 Ollama 模型和连接；重用合格索引，避免失败后重复嵌入；固定上下文配置。	预热成功只说明可调用，不代表答案正确。
Python 原生进程退出	Windows 事件记录涉及 `c10.dll` 访问异常；加无缓冲输出、故障日志、逐题检查点与续跑。	不能仅据退出位置认定模型显存是根因。
WinError 5 文件替换失败	独立临时文件、有限重试与退避，保留耐久元数据快照及修订号；逐题结果刷盘。	文件锁故障注入验证写入与恢复，不是模型质量提升。

这些改进服务于结果完整性与长任务可恢复性，是实际完成的工程稳定性工作；课程要求的生成/Agent 质量改进仍需以修复后的同题复测证明。不得把模拟故障注入的 55 条流程记录当作真实 55 题模型质量数据。

5.4 图表与报告生成设计

图采用一致的深蓝、青绿与赭色系统，全部同时导出矢量 PDF 和高分辨率 PNG。使用分面比较、逐题矩阵、分布图、散点图及共现矩阵，分别回答“总体差异、个体差异、效率代价与错误关联”。不使用无重复实验依据的误差棒、显著性标记或推测的优化曲线。表采用三线表、统一单位与小数精度，逐题明细使用跨页续表；图表数值均可从冻结 JSON 重建。

六、总结与展望

6.1 已完成成果与主要认识

本阶段形成了 15 篇论文、296 页、55 题四类问答的基准，完成真实 Agent 基线、495 条检索记录、AI 辅助评分与四类错误分析，并通过运行来源、哈希及独立目录维持可追溯性。在此样本上，512 字符配合混合检索加重排兼顾页级质量与耗时；Agent 的主要改进空间集中于完整性、文献绑定与引用支持，执行成功和工具集合匹配不足以代表答案可用。

报告交付包括一份可编辑 LaTeX 主文件、八组矢量与位图图形、七个数据表片段、冻结数据及复现脚本。成员 B 的工作价值在于提供能够复查的基线和具体修复入口，而不是以单一高分掩盖失败样本。

6.2 课程验收前的后续工作

表 12 待补事项与建议验收产物

待补工作	建议责任	可验收产物
独立人工复核 55 题	B 组织	评分者、日期、逐题理由、争议处理与签字记录。
路由、异常与论文绑定修复	C/D 实施，B 复测	新版代码指纹、同题新运行、优化前后指标及 Bad Case 迁移。
三类分块策略质量比较	C 实现，B 测量	固定语料与题集的 fixed/recursive/semantic 检索质量表。
真实界面截图 3–5 张	A/D	运行界面及核心区域标注，覆盖实际核心功能。
其余模块课程要求	对应负责人	多格式、嵌入/向量库对照、真实流式等逐项验收材料。

所有下一轮对照应固定题集与评分规则，失败保留在分母中，旧基线只读保存。若改变语料、模型或金标，应另建实验版本并解释变化，不能直接把不同条件下的得分当作修复收益。

七、附录

7.1 环境与关键配置

表 13 正式运行记录的环境与配置

类别	项目	版本或配置
运行环境	Python	3.10.20
	操作系统	Windows（build 26200）
生成模型	Ollama 模型	`qwen2.5:7b`
检索模型	Embedding	BAAI/bge-large-zh-v1.5
	Reranker	BAAI/bge-reranker-base
	推理设备	`cpu`
依赖版本	PyTorch	2.11.0+cu126
	Sentence Transformers	6.1.0
	ChromaDB / rank-bm25	1.5.9 / 0.2.2
	pdfplumber / Ollama SDK	0.11.10 / 0.6.3
生成参数	上下文窗口	4 096 token
	请求超时	120 s
Agent 参数	分块 / 重叠	512 / 50 字符
检索实验	递归字符块长	256 / 512 / 1024 字符
检索参数	候选 / 输出	20 / 5 个文本块
会话参数	Memory	关闭；每题独立会话
评分来源	性质	AI 辅助证据评分；未作独立人工复核

模型、依赖与请求参数取自冻结运行元数据；Ollama SDK 版本与独立服务版本不是同一概念。块长单位为字符，上下文窗口单位为 token。

注：模型名和版本取自运行元数据；CPU 指嵌入与重排设备，不能解释为 Ollama 全链路只用 CPU。

7.2 独立报告文件夹与编译

本目录可以整体复制，编译仅依赖目录内的图表文件与常规 LaTeX 环境；重建图表需要 Python、NumPy 与 Matplotlib，不需要再次调用 Ollama。`README.md` 说明脚本入口和字体回退。推荐用 XeLaTeX 编译两次：

```
xelatex -interaction=nonstopmode -halt-on-error main.tex
xelatex -interaction=nonstopmode -halt-on-error main.tex
```

报告源文件中的姓名、学号、班级、教师栏位应在提交前填写；填完后重新

编译。若使用便携 Tectonic，可执行 `tectonicmain.tex`。附带 PDF 是本次生成的阅读版本，编辑以 `main.tex` 为准。

7.3 本地实验复现命令

下列命令在原项目根目录执行，要求使用已安装项目依赖和模型的 NLP 环境。验证与汇总不会重新生成回答；正式运行会调用本地模型并写入新目录。不要覆盖原始基线。

```
# PowerShell: start in the original rag_project directory
$py = "D:\Anaconda\envs\NLP\python.exe"
& $py scripts\module5_eval.py check `
  --qa evaluation\qa.jsonl --data evaluation\corpus

# New Agent run; use a new output directory for each experiment
$stamp = Get-Date -Format "yyyyMMdd_HHmmss"
& $py scripts\module5_eval.py run `
  --mode agent --qa evaluation\qa.jsonl `
  --data evaluation\corpus --chunk-size 512 `
  --out "evaluation\runs\agent55_new_$stamp" --verbose

# Independent retrieval experiment; runs all three retrieval methods
$stamp = Get-Date -Format "yyyyMMdd_HHmmss"
& $py scripts\module5_eval.py run `
  --mode retrieval --qa evaluation\qa.jsonl `
  --data evaluation\corpus --chunk-size 512 `
  --out "evaluation\runs\retrieval55_new_$stamp" --verbose
```

256 与 1024 档仅更换 `--chunk-size` 并指定新目录。索引复用及续跑的参数和检查由脚本 `--help` 给出，不能跳过配置一致性验证。新模型运行不会自动生成独立人工评分；原 AI 评分也不能直接移植给新版回答。

7.4 原始记录与数据来源

原项目的主要代码结构如下，按实际文件整理；省略缓存、向量存储与临时日志，不照抄模板中的示例代码树。

```
rag_project/
  app.py
  src/
    data_loader/    # PDF parsing
    chunking/       # chunkers and size statistics
    retrieval/      # Chroma, BM25, hybrid, reranker
    generation/     # RAG pipeline
    agent/          # router, tools, ReAct, memory
    frontend/       # service and UI state
  scripts/
    module5_eval.py
    module5_tokens.py
    module5_charts.py
    run55.py
  evaluation/       # QA, corpus manifest, run records
  docs/
  tests/
  B_Module5_Report_20261014/
```

表 14 报告主要数据来源（均在原项目 evaluation 下）

记录	相对目录或文件
QA 与语料	qa.jsonl，corpus_manifest.json
Agent 基线	runs/agent55_20261014_175735_da23d1/
AI 辅助评分	ai_review_20261014_191222/scores_audit.json
评分后汇总	ai_review_20261014_191222/summary/summary.json
256 检索	runs/retrieval55_20261014_210831_0865ca/
512 检索	runs/retrieval55_20261014_193104_b35edd/
1024 检索	runs/retrieval55_20261014_212257_280fb9/
配置汇总	retrieval_comparison_20261014_214329/comparison.json

完整 SHA-256 及元数据见本包 data/source_manifest.json。为保持交付轻量，未复制约百兆字节的原始论文 PDF；参考摘录与页码保留在 QA 中，原论文仍由原项目 evaluation/corpus 提供。验证原始数据需使用该语料，阅读和编译报告不依赖它。

7.5 依据文档

本报告结构与验收边界参考用户提供的《南京农业大学课程实践.docx》与《项目交付模板.docx》；成员比例参考团队分工材料。报告中的所有实验结论以本地冻结记录为依据。八张图均为本次数据绘制或代码依赖示意，不是原论文插图，也不替代模板要求的真实界面截图。

7.6 文献清单

以下题名经本地 PDF 第一页文本与评测资料核对，页数为物理页。P 编号同时用于覆盖图；本表不补造未经核验的作者、出版年份或 DOI。

共 15 篇论文；页数为文件的 PDF 物理页数。文件名与哈希映射保存在包内数据文件。

表 15 15 篇本地论文与物理页清单

编号	论文题名（原文）	页数
P01	Video-LLaVA: Learning United Visual Representation by Alignment Before Projection	14
P02	Vision Mamba: Efficient Visual Representation Learning with Bidirectional State Space Model	14
P03	An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale	22
P04	Multi-View Semantic–Geometric Perception for Post-Disaster Flexible Suction with Metric 3D Scene Reconstruction	26
P05	Attention Is All You Need	15
P06	Deep Residual Learning for Image Recognition	9
P07	SBRF-Det: Scale-Boundary Representative Fusion for Multi-Finding Detection in Panoramic Dental Radiographs	35
P08	A Thermal-Aware Infrared–Visible Image Fusion Method for Defect Detection in Power Transmission Equipment	58
P09	Vision-Guided Cone Manipulation with Collaborative Robotic Arm	10
P10	Occlusion-Aware Watermelon Size Estimation Using YOLO11-OBB and Amodal GAN	8
P11	How to Choose a Suitable Method in Image Semantic Segmentation—An Experimental Study	6
P12	How to Benchmark Vision Foundation Models for Semantic Segmentation?	10
P13	An Intelligent Framework for Tooth Segmentation and Classification Through Fusion of Transfer Learning with Advanced Optimization Algorithms Using Biomedical Images	19

续下页

（续表）

编号	论文题名（原文）	页数
P14	Zero-Shot Water Monitoring from Fixed Drainage Surveillance Imagery Across Day/Night and Rain/No-Rain Conditions: A SAM 3 Benchmark at 25 Urban Sites	23
P15	Constructing a Xiangyunsha Defect Dataset and a Lightweight Detection Model for Sustainability	27
合计：15 篇		**296**

7.7 55 题评分明细

三列质量分数依次为正确性、完整性和引用准确性（0–2）；AI 路由为 0/1 的语义判断；自动匹配为固定可接受工具集合匹配。详细问题、参考答案与逐题理由分别见 `data/qa.jsonl` 和 `data/scores_audit.json`。全部评分仍需独立人工复核。

答案三维评分为 0–2；AI 语义路由与自动工具匹配为 0/1。AI 语义评分未经独立人工复核。

表 16 55 题逐题 AI 辅助评分与工具匹配明细

题号	类别	正确性（0–2）	完整性（0–2）	引用准确性（0–2）	AI 语义路由（0/1）	自动工具匹配（0/1）
F01	事实	2	2	2	1	1
F02	事实	1	1	1	0	1
F03	事实	0	0	0	0	0
F04	事实	0	0	0	0	0
F05	事实	1	2	1	1	1
F06	事实	2	2	2	1	1
F07	事实	0	0	0	0	0
F08	事实	0	0	0	0	0
F09	事实	1	1	1	1	1
F10	事实	2	2	2	1	1
F11	事实	1	1	1	1	1
F12	事实	0	0	0	0	0
F13	事实	0	0	0	0	0
F14	事实	2	2	2	1	1
F15	事实	1	1	1	1	1
F16	事实	0	0	0	1	1
F17	事实	1	1	0	1	1
F18	事实	0	0	0	0	1
F19	事实	0	0	0	1	1
F20	事实	0	0	0	1	1

续下页

（续表）

题号	类别	正确性（0–2）	完整性（0–2）	引用准确性（0–2）	AI 语义路由（0/1）	自动工具匹配（0/1）
C01	对比	1	1	1	1	1
C02	对比	1	1	1	1	1
C03	对比	0	0	0	1	1
C04	对比	1	1	1	1	1
C05	对比	1	0	1	1	1
C06	对比	1	1	1	1	1
C07	对比	1	1	1	1	1
C08	对比	1	1	1	1	1
C09	对比	1	0	1	1	1
C10	对比	2	0	2	1	1
C11	对比	1	1	1	1	1
C12	对比	2	1	2	1	1
C13	对比	2	1	2	1	1
C14	对比	1	1	1	1	1
C15	对比	1	1	1	1	1
S01	归纳	1	1	1	1	1
S02	归纳	2	1	2	1	1
S03	归纳	0	0	0	1	1
S04	归纳	1	1	1	1	1
S05	归纳	1	0	1	1	1
S06	归纳	1	1	1	0	0
S07	归纳	1	1	1	1	1
S08	归纳	2	1	2	1	1
S09	归纳	1	1	1	1	0
S10	归纳	0	0	0	0	0
R01	推理	1	1	0	1	1
R02	推理	1	1	1	1	1
R03	推理	2	2	2	1	1
R04	推理	2	2	2	1	1
R05	推理	1	1	1	1	1
R06	推理	1	1	1	1	1
R07	推理	2	2	2	1	1
R08	推理	0	0	1	1	1
R09	推理	1	1	1	1	1
R10	推理	2	1	2	1	1